



João Pedro de Sousa Moura

Rio de Janeiro-RJ
2024

```

import pandas as pd
from google.colab import drive
drive.mount('/content/drive')

# Carregar o arquivo CSV
df = pd.read_csv('/content/drive/My Drive/medium.csv')

# Garantir que temos as colunas corretas
df = df[['Title', 'Text']]

# Computar o TF-IDF
from sklearn.feature_extraction.text import TfidfVectorizer

tfidf_vectorizer = TfidfVectorizer(max_features=1000, stop_words='english')
tfidf_matrix = tfidf_vectorizer.fit_transform(df['Text'])

# Aplicar o LDA
from sklearn.decomposition import LatentDirichletAllocation

lda = LatentDirichletAllocation(n_components=5, random_state=42)
lda.fit(tfidf_matrix)

# Visualizar os tópicos
def display_topics(model, feature_names, no_top_words):
    for topic_idx, topic in enumerate(model.components_):
        print(f"Topic {topic_idx}:")
        print(" ".join([feature_names[i] for i in topic.argsort()[::-no_top_words - 1:-1]]))

tfidf_feature_names = tfidf_vectorizer.get_feature_names_out()
display_topics(lda, tfidf_feature_names, 10)

# Separar os dados em treino e teste
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score

df['label'] = df.index % 2
X_train, X_test, y_train, y_test = train_test_split(tfidf_matrix, df['label'], test_size=0.2, random_state=42)

```

```

# Treinar um modelo de classificação
# Removing the 'model' variable to avoid conflicts
clf = MultinomialNB()
clf.fit(X_train, y_train)

# Fazer previsões
y_pred = clf.predict(X_test)

# Avaliar o desempenho do modelo
accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred)
recall = recall_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)
roc_auc = roc_auc_score(y_test, y_pred)

print(f"Accuracy: {accuracy}")
print(f"Precision: {precision}")
print(f"Recall: {recall}")
print(f"F1 Score: {f1}")
print(f"ROC-AUC Score: {roc_auc}")

# Visualizar os agrupamentos
from sklearn.manifold import TSNE
import matplotlib.pyplot as plt

tsne = TSNE(n_components=2, random_state=42)
tsne_results = tsne.fit_transform(tfidf_matrix.toarray())

plt.figure(figsize=(10, 6))
plt.scatter(tsne_results[:, 0], tsne_results[:, 1], c=df['label'])
plt.title('t-SNE visualization of topics')
plt.show()

```


```
# Utilizar SHAP para explicar as previsões individuais
import shap

# Using the classifier object 'clf' directly
explainer = shap.Explainer(clf, X_train)
shap_values = explainer.shap_values(X_test)

# Visualizar a contribuição das features para uma previsão específica
shap.force_plot(explainer.expected_value[1], shap_values[1][0,:], X_test[0,:], feature_names=tfidf_feature_names)
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
Topic 0:
data model learning using function use dataset image code training
Topic 1:
install git docker command environment jupyter server packages notebooks notebook
Topic 2:
data science business scientist skills scientists analytics job company team
Topic 3:
ai learning data human machine people intelligence computer artificial research
Topic 4:
agent player action reward games policy actions game agents reinforcement
Accuracy: 0.5268817204301075
Precision: 0.5075757575757576
Recall: 0.5
F1 Score: 0.5037593984962406
ROC-AUC Score: 0.5258620689655172
```

Figure 1



7)

1)

Desempenho do modelo de classificação: O modelo Multinomial Naive Bayes classificou corretamente um pouco mais da metade das instâncias de teste, com uma acurácia de aproximadamente 52,7%.

2)

Precisão, Recall e F1-Score: A precisão foi de aproximadamente 50,8%, o recall foi de 50% e o F1-Score foi de cerca de 50,4%, indicando um desempenho equilibrado entre a precisão e a capacidade de recuperar

informações relevantes.

3)

AUC-ROC Score: O modelo obteve um AUC-ROC Score de aproximadamente 52,6%, um pouco melhor do que um modelo aleatório, mas ainda com margem para melhorias na classificação.

4)

Visualização dos Agrupamentos: A visualização t-SNE dos agrupamentos não mostra uma separação clara entre os grupos, sugerindo que os documentos podem não estar bem distintos em termos de tópicos.

5)

Tópicos Identificados pelo LDA: O modelo LDA identificou cinco tópicos principais nos documentos, relacionados a diferentes áreas como ciência de dados, aprendizado de máquina e inteligência artificial.

Link para o colab:

https://colab.research.google.com/drive/16bQb5pRmLWVlwc_lbC8iNKHEe_bd2EDy0?usp=sharing